

# Школа анализа данных

## Машинное обучение, часть 2

### Домашнее задание №1

Решите предложенные задачи. Решения необходимо оформить в виде PDF документа. Каждая задача должна быть подробно обоснована, задачи без обоснования не засчитываются. Решения пишутся в свободной форме, однако так, чтобы проверяющие смогли разобраться. Если проверяющие не смогут разобраться в решении какой-нибудь задачи, то она автоматически не засчитывается. Дедлайн очников 9 октября 2018 09:00MSK, дедлайн заочников и филиалов +2 суток.

#### Задача 1 (0.5 балла) Нейронные сети.

Реализуйте следующую булеву функцию трех переменных с помощью нейронной сети:

$$f(x) = (\bar{x}_1 \vee x_3) \& (x_1 \vee x_2 \vee x_3).$$

Все нейроны должны использовать функцию активации  $\sigma(x) = [x > 0]$ .

#### Задача 2 (1.5 балла) Нейронные сети, back-prop.

Рассмотрим двуслойную полносвязную нейронную сеть, применяемую для задачи классификации. На вход нейронной сети подается вектор признаков  $x$  размерности  $n$ , полносвязный слой с матрицей весов  $W$  размерности  $n \times d$  преобразует вектор  $x$  в скрытое представление  $h$  некоторой размерности  $d$ :

$$h = xW$$

Функции активации нет, еще один полносвязный слой с матрицей весов  $W'$  размерности  $d \times m$  преобразует скрытое представление в вектор оценок  $a$  принадлежности к каждому классу. Чтобы получить из этих оценок вероятности, используется softmax. Например, вероятность того, что объект, описываемый вектором признаков  $x$ , относится к классу  $j$  согласно нейронной сети выглядит так:

$$p_j = \frac{\exp(a_j)}{\sum_{k=1}^m \exp(a_k)}$$

В качестве функции потерь используется cross-entropy loss:

$$\mathcal{L} = - \sum_{j=1}^m y_j \log p_j,$$

где  $y$  – one-hot encoding истинной метки объекта.

Итак, мы полностью описали проход по нейронной сети вперед: как по входному вектору  $x$  найти вероятности классов  $p_j$  и вычислить значение функции потерь, зная ответ  $y$  на рассматриваемом объекте. Опишите обратный проход по нейронной сети: выпишите формулы изменения матриц весов  $W$  и  $W'$  в стохастическом градиентном спуске для метода обратного распространения ошибки (backpropagation).

**Задача 3. Нейронные сети, инициализация весов.**

Рассмотрим полносвязный слой нейронной сети с матрицей весов  $W$  и свободным членом  $b$ , получающий на вход вектор  $x$  размерности  $n$  и вычисляющий скрытое представление размерности  $m$

$$h = Wx + b.$$

Предложите, из какого невырожденного вероятностного распределения надо выбирать веса  $W$  и  $b$ , чтобы активации  $h$  имели нормальное распределение  $N(0, \sigma^2)$ , если

- (a) **(1 балл)** Все признаки независимы и распределены по стандартному нормальному закону.
- (b) **(2 балла)** Все признаки независимы и распределены равномерно от 0 до  $a$ .

Распределения  $W$  и  $b$  не обязаны совпадать, они могут быть из разных семейств.

**Задача 4 (1.5 балла) Композиции алгоритмов, бустинг, AdaBoost.**

Обозначим через  $\tilde{w}^{(N)}$  нормированный вектор весов на  $N$ -й итерации алгоритма AdaBoost. Покажите, что взвешенная ошибка базового классификатора  $b_N$  относительно весов со следующего шага  $\tilde{w}_i^{(N+1)}$  равна  $1/2$ :

$$\sum_{i=1}^{\ell} \tilde{w}_i^{(N+1)} [b_N(x_i) \neq y_i] = \frac{1}{2}.$$

**Задача 5 (2 балла) Градиентный бустинг.**

- Какой функции потерь будет соответствовать градиентный бустинг, который на каждой итерации настраивается на разность между вектором истинных меток и текущим вектором предсказанных меток?
- Градиентный бустинг обучается на пяти объектах с функцией потерь для одного объекта

$$\mathcal{L}(\tilde{y}, y) = (\tilde{y} - y)^4.$$

На некоторой итерации полученная композиция дает ответ  $(5, 10, 6, 3, 0)$ . На какой вектор ответов будет настраиваться следующий базовый алгоритм, если истинный вектор ответов равен  $(6, 8, 6, 4, 1)$ ?

- Рассмотрим задачу бинарной классификации,  $Y = \{0, 1\}$ . Будем считать, что все алгоритмы из базового семейства  $\mathcal{A}$  возвращают ответы из отрезка  $[0, 1]$ , которые можно интерпретировать как вероятности принадлежности объекта к классу 1. В качестве функции потерь возьмем отрицательный логарифм правдоподобия (negative log-likelihood):

$$L(y, z) = -(y \log z + (1 - y) \log(1 - z)),$$

где  $y$  — правильный ответ, а  $z$  — ответ алгоритма.

Выпишите формулы для поиска базовых алгоритмов  $b_n$  и коэффициентов  $\gamma_n$  в градиентном бустинге.

**Задача 6 (1.5 балла) Композиции, устойчивость к шуму.**

- Рассмотрим алгоритм AdaBoost — бустинг с экспоненциальной функцией потерь

$$\mathcal{L}(M) = \exp(-M),$$

где  $M$  — отступ объекта. Покажите, что алгоритм неустойчив к шуму, т.е. возможен неограниченный рост отношения весов шумовых объектов по отношению к весам пороговых объектов.

2. Покажите, что бустинг с логистической функцией потерь

$$\mathcal{L}(M) = \log(1 + \exp(-M))$$

устойчив к шуму в описанном выше смысле.

Примечание. Пороговые объекты — это те, для которых значение отступа положительно и порядка нуля, то есть они лежат близко к границе между классами и в своем классе. Шумовые объекты лежат глубоко в чужом классе, на них отступ принимает большие отрицательные значения.